ทักษะปัญญาประดิษฐ์เพื่อชีวสารสนเทศ จีโนมิกส์ และวิทยาศาสตร์ชีวภาพเชิงคำนวณ

Series of AI SKILL — Volume 07: AI for Bioinformatics, Genomics & Computational Life Sciences

ผู้ช่วยศาสตราจารย์ ดร.ชีวะ ทัศนา

สาขาวิชาฟิสิกส์ คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยราชภัฏรำไพพรรณี

ศูนย์ความเป็นเลิศด้านสิ่งแวดล้อมและพลังงาน (LEQs) • พ.ศ. 2569

Contents

1 การทำนายและการวิเคราะห์โครงสร้าง 3 มิติของโปรตีนด้วย AlphaFold DB **1**

1.1 สถาปัตยกรรม Evoformer และการพับตัวของโครงสร้าง 1

1.2 การแปลความหมายดัชนีความเชื่อมั่น pLDDT 1

1.3 การสืบค้นความคล้ายคลึงของโครงสร้างด้วย Foldseek 2

2 การทำนายผลกระทบของการกลายพันธุ์ระดับจีโนมด้วย AlphaGenome **3**

2.1 การวิเคราะห์บริเวณควบคุมยีนด้วย Deep Learning 3

2.2 การประเมินการเข้าถึงของโครมาติน 3

2.3 การจัดกลุ่มความรุนแรงของโรคด้วย Ensembl VEP และ ClinVar 4

3 เคมีสารสนเทศและการค้นหายาใหม่ด้วย ChEMBL, PubChem และ PyMOL **5**

3.1 ฐานข้อมูลสารออกฤทธิ์ทางชีวภาพ ChEMBL 5

3.2 การสืบค้นโครงสร้างและคุณสมบัติทางเคมีด้วย PubChem 6

3.3 การสร้างภาพจำลองปฏิสัมพันธ์โมเลกุลด้วย PyMOL 6

A คลังรหัสและองค์ประกอบสกิลชีวสารสนเทศและวิทยาศาสตร์ชีวภาพ **7**

A.1 สกิล: alphafold-database-fetch-and-analyze . . 7

A.1.1 โค้ดแกนกลาง: สคริปต์วิเคราะห์โครงสร้าง 3 มิติและคะแนน pLDDT 7

A.2 สกิล: alphagenome-single-variant-analysis . . . 8

A.2.1 โครงสร้างคำขอวิเคราะห์การกลายพันธุ์ (Payload Specification) 8

A.3 สกิล: chembl-database 9
A.3.1 โค้ดแกนกลาง: การดึงค่าความสัมพันธ์ IC50 ของเป้าหมายยา 9

บทที่ 1

การทำนายและการวิเคราะห์โครงสร้าง 3 มิติของโปรตีนด้วย AlphaFold DB

การพับตัวของโปรตีน (Protein Folding) เป็นหนึ่งในปริศนาทางชีววิทยาที่ยิ่งใหญ่ที่สุด การมาถึงของ AlphaFold ช่วยเปลี่ยนผ่านจากการทดลองในห้องปฏิบัติการที่ใช้เวลาหลายเดือน สู่การทำนายโครงสร้างระดับอะตอมได้ภายในไม่กี่นาที

1.1 สถาปัตยกรรม Evoformer และการพับตัวของโครงสร้าง

โมเดล AlphaFold ใช้สถาปัตยกรรม Evoformer ในการประมวลผลการจัดเรียงลำดับเบสหลายชุด (Multiple Sequence Alignment: MSA) ร่วมกับเมทริกซ์ระยะห่างของคู่กรดอะมิโน (Residue Pair Representations) เพื่ออนุมานความสัมพันธ์เชิงพื้นที่ใน 3 มิติ

1.2 การแปลความหมายดัชนีความเชื่อมั่น pLDDT

ค่า Predicted Local Distance Difference Test (pLDDT) มีช่วงคะแนนตั้งแต่ 0 ถึง 100 ใช้บ่งชี้ความมั่นใจของโมเดล:

- **pLDDT > 90 (สีน้ำเงินเข้ม):** ความเชื่อมั่นสูงมาก โครงสร้างสายข้าง (Side Chains) มีความแม่นยำระดับอะตอม
- **70 < pLDDT < 90 (สีฟ้าอ่อน):** ความเชื่อมั่นระดับดี โครงสร้างแกนหลัก (Backbone) เชื่อถือได้
- **50 < pLDDT < 70 (สีเหลือง):** ความเชื่อมั่นต่ำ ควรระมัดระวังในการแปลผล
- **pLDDT < 50 (สีส้มแดง):** บริเวณที่ไม่มีโครงสร้างชัดเจน (Intrinsically Disordered Regions: IDR)

1.3 การสืบค้นความคล้ายคลึงของโครงสร้างด้วย Foldseek

เมื่อต้องการเปรียบเทียบโครงสร้างที่ทำนายได้กับคลังข้อมูล PDB ทั่วโลก Foldseek แปลงโครงสร้าง 3 มิติให้อยู่ในรูปตัวอักษร 3Di (3D Interaction Alphabet) ทำให้ค้นหาโครงสร้างที่คล้ายกันได้เร็วกว่าวิธีเดิมนับพันเท่า

บทที่ 2

การทำนายผลกระทบของการกลายพันธุ์ระดับจีโนมด้วย AlphaGenome

การกลายพันธุ์ของสารพันธุกรรมไม่ได้เกิดขึ้นเฉพาะในยีนที่สังเคราะห์โปรตีนเท่านั้น บริเวณนอนโค้ดดิ้ง (Non-coding Regions) ซึ่งคิดเป็นร้อยละ 98 ของจีโนมมนุษย์ มีบทบาทสำคัญในการควบคุมการแสดงออกของยีนและกลไกการเกิดโรค

2.1 การวิเคราะห์บริเวณควบคุมยีนด้วย Deep Learning

AlphaGenome อาศัยโครงข่ายประสาทเทียมชนิด Deep Convolutional Transformer เพื่อทำนายการเปลี่ยนแปลงของการแสดงออกของยีน (Gene Expression: RNA-seq) เมื่อเกิดการแทนที่เบสเดี่ยว (Single Nucleotide Variant: SNV)

2.2 การประเมินการเข้าถึงของโครมาติน

สัญญาณการเปิดของโครมาติน (Chromatin Accessibility) บ่งชี้ว่าปัจจัยควบคุมการถอดรหัส (Transcription Factors: TFs) สามารถเข้าจับกับดีเอ็นเอได้หรือไม่:

$$\Delta\text{Accessibility} = \mathcal{P}(\text{DNASE} \mid \text{Alt}) - \mathcal{P}(\text{DNASE} \mid \text{Ref}) \quad (2.1)$$

หากค่า ΔAccessibility มีค่าเป็นลบอย่างมีนัยสำคัญ แสดงว่าการกลายพันธุ์นั้นอาจทำลายตำแหน่งจับของปัจจัยควบคุม ส่งผลให้ยีนเป้าหมายหยุดการทำงาน

2.3 การจัดกลุ่มความรุนแรงของโรคด้วย Ensembl VEP และ ClinVar

การเชื่อมต่อกับ Ensembl Variant Effect Predictor (VEP) ช่วยให้นักวิจัยสามารถประเมินผลกระทบต่อโครงสร้างรหัสพันธุกรรม (Missense, Frameshift, Stop Gained) และเปรียบเทียบกับบันทึกประวัติทางคลินิกใน ClinVar ได้แบบอัตโนมัติ

บทที่ 3

เคมีสารสนเทศและการค้นหายาใหม่ด้วย ChEMBL, PubChem และ PyMOL

กระบวนการค้นหายาและพัฒนาสารออกฤทธิ์ทางชีวภาพ (Drug Discovery) ได้รับประโยชน์อย่างมหาศาลจากการบูรณาการโมเดลเคมีเชิงคำนวณเข้ากับฐานข้อมูลชีวโมเลกุลขนาดใหญ่

3.1 ฐานข้อมูลสารออกฤทธิ์ทางชีวภาพ ChEMBL

ChEMBL รวบรวมข้อมูลโมเลกุลขนาดเล็กที่มีการทดลองวัดค่าการยับยั้งเอนไซม์หรือตัวรับสัญญาณ (Bioactivity Assays) โดยมีตัวชี้วัดสำคัญได้แก่:

- **IC50 (Half Maximal Inhibitory Concentration):** ความเข้มข้นของสารที่ยับยั้งการทำงานของโปรตีนได้ร้อยละ 50
- **Ki (Inhibition Constant):** ค่าคงที่การยับยั้งทางอุณหพลศาสตร์
- **Lipinski's Rule of Five:** กฎ 5 ข้อสำหรับประเมินความเป็นไปได้ในการพัฒนาเป็นยารับประทาน

3.2 การสืบค้นโครงสร้างและคุณสมบัติทางเคมีด้วย PubChem

PubChem เป็นคลังข้อมูลสารเคมีที่ใหญ่ที่สุดในโลก การสืบค้นสามารถทำผ่านรหัสระบุชนิดสาร (CID), รหัสโครงสร้างแบบบรรทัดเดียว (SMILES), หรือการเปรียบเทียบความคล้ายคลึงของโครงสร้างโมเลกุล (Tanimoto Similarity Coefficient):

$$T(A,B) = \frac{|A \cap B|}{|A \cup B|} \tag{3.1}$$

3.3 การสร้างภาพจำลองปฏิสัมพันธ์โมเลกุลด้วย PyMOL

เมื่อได้สารที่มีศักยภาพแล้ว ซอฟต์แวร์ PyMOL จะถูกนำมาใช้สร้างแบบจำลอง 3 มิติเพื่อแสดงพันธะไฮโดรเจน (Hydrogen Bonds), แรงดึงดูดทางไฟฟ้าสถิต (Electrostatic Interactions), และโพรงที่จับของยา (Binding Pocket Surface) ช่วยให้นักวิจัยเข้าใจกลไกการออกฤทธิ์ในระดับชีวฟิสิกส์ได้อย่างลึกซึ้ง

บทที่ A

คลังรหัสและองค์ประกอบสกิลชีวสารสนเทศและวิทยาศาสตร์ชีวภาพ

ภาคผนวกนี้รวบรวมข้อมูลจำเพาะ โค้ดต้นแบบ และสถาปัตยกรรมระดับองค์กรของสกิล AlphaFold DB, AlphaGenome, Foldseek, ChEMBL, และ PyMOL ประจำเล่มที่ 7

A.1 สกิล: alphafold-database-fetch-and-analyze

[แผนการสอน] ข้อมูลจำเพาะและเมทาดาทาของสกิล

ชื่อสกิล: `alphafold-database-fetch-and-analyze`
วัตถุประสงค์: ดึงและประเมินความเชื่อมั่นโครงสร้างโปรตีน 3 มิติจาก UniProt Accession ID
ตัวชี้วัดสำคัญ: pLDDT Scores, Predicted Alignment Error (PAE), Domain Boundaries

A.1.1 โค้ดแกนกลาง: สคริปต์วิเคราะห์โครงสร้าง 3 มิติและคะแนน pLDDT

```python
import requests

def fetch_alphafold_structure(uniprot_id):
    url = f"https://alphafold.ebi.ac.uk/api/prediction/{uniprot_id}"
    response = requests.get(url)
    if response.status_code != 200:
        raise ValueError(f"UniProt ID {uniprot_id} not found in AlphaFold DB")

    data = response.json()[0]
    cif_url = data["cifUrl"]
    pdb_url = data["pdbUrl"]
    bcif_url = data["bcifUrl"]

    return {
        "uniprot_id": uniprot_id,
        "entry_id": data["entryId"],
        "gene": data.get("gene", "N/A"),
        "cif_url": cif_url,
        "pdb_url": pdb_url
    }
```

Listing A.1: AlphaFold DB API Structure Fetcher and Analyzer

A.2 สกิล: alphagenome-single-variant-analysis

[แผนการสอน] ข้อมูลจำเพาะและเมทาดาทาของสกิล

ชื่อสกิล: `alphagenome-single-variant-analysis`
วัตถุประสงค์: ทำนายผลกระทบของการกลายพันธุ์ระดับเบสต่อการแสดงออกของยีนและโครมาติน
ฟังก์ชันการทำงาน: RNA-seq Effect, Chromatin Accessibility (DNASE), Histone Marks

A.2.1 โครงสร้างคำขอวิเคราะห์การกลายพันธุ์ (Payload Specification)

```javascript
const VariantQuery = {
```

```
  chromosome: "chr7",
  position: 117199646,
  reference_allele: "C",
  alternate_allele: "A",
  genome_assembly: "GRCh38",
  target_assays: ["RNA_SEQ", "DNASE", "CHIP_H3K27AC"],
  tissue_ontology: "UBERON:0002048" // Lung tissue
};
```

Listing A.2: AlphaGenome Variant Query Payload

A.3 สกิล: chembl-database

[แผนการสอน] ข้อมูลจำเพาะและเมทาดาทาของสกิล

ชื่อสกิล: `chembl-database`
วัตถุประสงค์: ค้นหาโมเลกุลยาเป้าหมาย ค่าการยับยั้งเอนไซม์ (IC50, Ki) และโครงสร้างเคมี
ขอบเขตเทคโนโลยี: ChEMBL REST API, SMILES Substructure Search, Bioactivity Assays

A.3.1 โค้ดแกนกลาง: การดึงค่าความสัมพันธ์ IC50 ของเป้าหมายยา

```
import requests

def get_target_ic50(target_chembl_id):
    endpoint = "https://www.ebi.ac.uk/chembl/api/data/
        activity.json"
    params = {
        "target_chembl_id": target_chembl_id,
        "standard_type": "IC50",
        "limit": 10
    }
    res = requests.get(endpoint, params=params)
    activities = res.json().get("activities", [])

    return [{
        "molecule_chembl_id": a["molecule_chembl_id"],
        "standard_value": a["standard_value"],
```

```
        "standard_units": a["standard_units"]
    } for a in activities if a.get("standard_value")]
```

Listing A.3: ChEMBL Bioactivity Query Script